

Laporan Kemajuan Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Rafael Hartono (24031554166)
Anggota 1	Athiyyatus Salisah (24031554223)
Anggota 2	Nurul Aini (24031554060)
URL Github	https://github.com/rafaelhartono8/166_060_223_Machine-Learning

Informasi Umum Proyek

Judul	<i>Analisis Perbandingan Algoritma Random Forest Regression, XGBoost, dan LSTM untuk Prediksi Daya Panel Surya Berdasarkan Data Meteorologi pada Wilayah 3T di Indonesia</i>
Topik	<i>Energi</i>
Pilihan Rumusan Masalah	3.8 Minimnya Pemanfaatan IoT dan AI untuk Ekspansi Elektrifikasi di Daerah 3T
Revisi?	<i>Ya / Tidak</i>

Informasi Detil Dataset

Sumber dataset	Dataset yang digunakan pada penelitian ini diperoleh melalui proses scraping data dari layanan API resmi PVGIS (Photovoltaic Geographical Information System) milik European Commission Joint Research Centre (JRC). API yang digunakan adalah layanan non-interactive service PVGIS 5.2 yang dapat diakses melalui link ini . Proses pengambilan data dilakukan secara otomatis menggunakan bahasa pemrograman Python dengan bantuan library requests dan pandas. Data diambil melalui API PVGIS untuk beberapa kota di Indonesia dengan parameter koordinat lintang dan bujur (latitude dan longitude) masing-masing kota. Data yang diambil mencakup periode tahun 2015 hingga 2020 dengan resolusi data per jam (hourly data). Data hasil scraping yaitu sebanyak 2439968 baris, 8 kolom, dan ukuran file sebesar 122.12 MB.		
Deskripsi awal fitur dataset	Tuliskan nama-nama atribut dataset berikut dengan: deskripsi dan tipe data nya.		
	Dataset yang digunakan dalam proyek ini terdiri dari beberapa atribut yang berkaitan dengan kondisi lingkungan dan estimasi energi panel surya. Berikut merupakan deskripsi masing-masing atribut beserta tipe datanya:		
	Nama Atribut	Deskripsi	Tipe Data
	Datetime	Tanggal dan waktu pengamatan data energi surya	Datetime / object
	SolarIrradiance	Intensitas radiasi matahari yang diterima permukaan panel surya.	Float
	SunHeight	Ketinggian posisi matahari terhadap horizon	Float


		pada waktu tertentu	
	Temperature	Suhu udara pada lokasi pengamatan	Float
	WindSpeed	Suhu udara pada lokasi pengamatan	Float
	Int	intensitas kondisi cuaca tertentu yang diperoleh dari hasil API PVGIS.	Float
	PowerOutput	Estimasi daya listrik yang dihasilkan panel surya. Atribut digunakan sebagai target prediksi.	Float
	City	Nama kota lokasi pengambilan data panel surya di Indonesia	Object/String
Detil-detil langkah pre-processing	Tuliskan secara runtut langkah-langkah pre-processing.		
	Tahap <i>pre-processing</i> dilakukan untuk meningkatkan kualitas data sebelum dilakukan pemodelan sebagai berikut: 1. Membaca dataset 2. Memeriksa Struktur dan kondisi dataset. di bagian ini untuk melihat Informasi datanya mulai dari tipe datanya, datanya mempunyai Kolom dan baris berapa, mendeteksi missing value , Mendeteksi Duplikat data. Tetapi disini data hasil scraping dari API PVGIS tidak memiliki missing value dan Duplikat data 3. Transformasi Tipe data Datetime. Pada tahap ini dilakukan transformasi kolom Datetime dari bentuk string menjadi format datetime menggunakan library pandas 4. Sorting Data Berdasarkan Waktu. Pada tahap ini dilakukan pengurutan data (<i>sorting</i>) berdasarkan kolom City dan Datetime menggunakan fungsi <code>sort_values()</code>. Proses ini bertujuan untuk memastikan bahwa data time series tersusun secara kronologis sesuai urutan waktu pada setiap wilayah pengamatan. 5. Agregasi Harian. Pada tahap ini dilakukan proses agregasi data dari skala waktu per jam menjadi skala harian. Agregasi dilakukan karena penelitian berfokus pada forecasting daya panel surya harian sehingga data perlu direpresentasikan dalam bentuk total dan rata-rata harian. Setelah di agregasi data menjadi 92064 baris. 6. Feature Engineering. Pada penelitian ini digunakan beberapa feature engineering, yaitu lag feature untuk merepresentasikan data pada periode sebelumnya, rolling mean untuk menangkap tren dan mengurangi noise data, serta time feature seperti bulan, hari, dan tahun untuk membantu model mengenali pola musiman dan perubahan cuaca berdasarkan waktu pengamatan. Setelah proses feature engineering selesai, data yang memiliki nilai kosong akibat proses lag dan rolling mean dihapus agar dataset siap digunakan pada tahap pemodelan. 7. Data Splitting. Pada tahap data splitting, dataset dibagi menjadi data training dan data testing berdasarkan urutan waktu tanpa pengacakan data (<code>shuffle=False</code>) agar pola time series tetap terjaga. Data tahun 2015–2019 digunakan sebagai data training, sedangkan data tahun 2020 digunakan sebagai data testing. Hasil pembagian data menunjukkan data training berjumlah 76.608 data dan data testing berjumlah 15.372 data.		

	8. Scaling / normalisasi data. Pada tahap ini dilakukan normalisasi data menggunakan metode MinMaxScaler untuk mengubah rentang nilai data menjadi skala 0 hingga 1. Normalisasi dilakukan pada data feature (X) dan target (y) sebelum proses pemodelan, terutama untuk model LSTM yang sensitif terhadap perbedaan skala data. Proses normalisasi dilakukan dengan <code>fit_transform()</code> pada data training dan <code>transform()</code> pada data testing agar informasi dari data testing tidak mempengaruhi proses pelatihan model. Tahap ini bertujuan untuk mempercepat proses training, meningkatkan stabilitas model, serta membantu model dalam mempelajari pola data secara lebih optimal.
--	---

Kemajuan Pengerjaan

Teknik yang digunakan	<i>Tuliskan teknik/algorithm yang sedang digunakan dalam proyek, misal: MLP / RNN / Ensemble Stacking, dst.</i> Penelitian ini menggunakan teknik machine learning dan deep learning untuk prediksi daya panel surya berbasis data time series meteorologi. Algoritma yang digunakan meliputi Random Forest Regression, XGBoost Regression, dan Long Short-Term Memory (LSTM). Selain itu, Penelitian ini juga menerapkan teknik time series forecasting dengan feature engineering temporal seperti lag feature, rolling mean, dan time feature untuk membantu model memahami pola historis dan tren data daya panel surya. Selain itu, dilakukan normalisasi data menggunakan MinMaxScaler untuk meningkatkan stabilitas dan performa model pada proses pelatihan dan prediksi.
Nilai metrik terakhir	<i><u>Uraikan</u> nilai-nilai metrik yang sudah didapat dari proses-proses latih. Accuracy sudah berapa? F1 sudah berapa?</i> Pada penelitian ini, evaluasi model dilakukan menggunakan metrik regresi yaitu MAE, MSE, RMSE, dan R^2 Score untuk mengukur tingkat kesalahan dan akurasi prediksi daya panel surya. Hasil Evaluasi menunjukkan - Random Forest Regression MAE : 15.0669 MSE : 539.4395 RMSE: 23.2258 R^2 Score: 0.999758 - XGBoost Regression MAE : 15.02366 MSE : 496.701 RMSE: 22.28679 R^2 Score: 0.999777 - LSTM MAE : 372.4816 MSE : 293080.413 RMSE: 541.3690 R^2 Score: 0.868582 Berdasarkan hasil evaluasi ketiga model yang digunakan, yaitu Random Forest Regression, XGBoost Regression, dan LSTM, dapat disimpulkan bahwa model berbasis tree ensemble memberikan performa yang sangat baik dalam melakukan prediksi data. Random Forest Regression menghasilkan nilai MAE sebesar 15.0669, MSE sebesar 539.4395, RMSE sebesar 23.2258, serta R^2 sebesar 0.999758. Nilai R^2 yang sangat tinggi menunjukkan bahwa model ini mampu menjelaskan hampir seluruh variasi data dengan tingkat kesalahan yang relatif kecil.


	XGBoost Regression memberikan hasil yang sedikit lebih baik dibandingkan Random Forest. Model ini memperoleh MAE sebesar 15.02366, MSE sebesar 496.701, RMSE sebesar 22.28679, dan R^2 sebesar 0.999777. Penurunan nilai error serta peningkatan R^2 menunjukkan bahwa XGBoost lebih optimal dalam menangkap pola hubungan non-linear pada data dibandingkan Random Forest. Sementara itu, model LSTM menunjukkan performa yang jauh lebih rendah dibandingkan kedua model sebelumnya. LSTM menghasilkan MAE sebesar 372.4816, MSE sebesar 293080.413, RMSE sebesar 541.3690, dan R^2 sebesar 0.868582. Nilai error yang jauh lebih besar mengindikasikan bahwa model belum mampu mempelajari pola data secara optimal, sehingga hasil prediksinya masih kurang akurat. Secara keseluruhan, dapat disimpulkan bahwa model terbaik untuk kasus ini adalah XGBoost Regression, karena memiliki tingkat error paling rendah dan nilai R^2 tertinggi dibandingkan model lainnya.
Visualisasi grafik latih dan validasi	<i>Berikan plot latih atau validasi yang sudah didapat</i> Berikut ini adalah visualisasi hasil prediksi daya panel surya menggunakan model Random Forest, XGBoost, dan LSTM: Gambar 1. Grafik <i>Actual vs Prediction</i> pada model Random Forest Berdasarkan grafik <i>Actual vs Prediction</i> pada model Random Forest, terlihat bahwa garis hasil prediksi hampir selalu berdekatan dengan garis data aktual. Hal ini menunjukkan bahwa model Random Forest mampu mempelajari pola hubungan antara variabel meteorologi dan output daya panel surya dengan sangat baik. Model dapat mengikuti kenaikan dan penurunan nilai output daya pada sebagian besar data pengujian. Bahkan pada beberapa titik dengan perubahan nilai yang cukup signifikan, hasil prediksi masih mampu mendekati nilai aktual. Kondisi tersebut menunjukkan bahwa model memiliki kemampuan generalisasi yang baik dalam memprediksi daya panel surya harian. Selain itu, tidak terlihat perbedaan yang terlalu jauh antara garis prediksi dan garis aktual, sehingga tingkat error model relatif kecil. Hasil visualisasi ini juga mendukung hasil evaluasi sebelumnya yang menunjukkan nilai R^2 sangat tinggi dan nilai MAE serta RMSE yang rendah. Oleh karena itu, model Random Forest dapat dikatakan memiliki performa yang sangat baik untuk melakukan prediksi daya panel surya berdasarkan data meteorologi pada penelitian ini.



Gambar 2. Grafik *Actual vs Prediction* pada model XGBoost

Grafik tersebut menunjukkan perbandingan antara nilai aktual (*Actual*) dan hasil prediksi model XGBoost terhadap *Power Output*. Secara umum, terlihat bahwa garis prediksi (oranye) mengikuti pola garis aktual (biru) dengan sangat dekat di hampir seluruh data. Hal ini menunjukkan bahwa model XGBoost mampu menangkap pola fluktuasi data dengan cukup baik, termasuk perubahan naik turun yang cukup tajam pada beberapa titik. Kedekatan antara nilai aktual dan prediksi ini mengindikasikan bahwa model memiliki tingkat akurasi yang tinggi dalam memodelkan hubungan antara variabel input dan output.

Meskipun demikian, masih terdapat beberapa titik di mana prediksi sedikit menyimpang dari nilai aktual, terutama pada kondisi perubahan yang ekstrem atau lonjakan yang tiba-tiba. Secara keseluruhan, hasil ini menunjukkan bahwa model XGBoost yang digunakan memiliki performa yang baik dan cukup stabil dalam melakukan prediksi *Power Output*, sehingga dapat dikatakan model tersebut sudah layak digunakan untuk analisis maupun prediksi data energi.



Gambar 3. Training and Validation Loss

Berdasarkan grafik *Training vs Validation Loss* pada model LSTM, terlihat bahwa nilai training loss mengalami penurunan yang cukup stabil seiring bertambahnya epoch, yang menunjukkan bahwa model mampu mempelajari pola dari data training dengan baik. Namun, pada sisi validation loss, penurunan yang terjadi tidak secepat training loss dan cenderung stagnan serta berfluktuasi kecil pada nilai yang relatif lebih tinggi dibandingkan training loss. Kondisi ini menunjukkan adanya indikasi overfitting ringan, di mana model masih dapat meningkatkan performa pada data training, tetapi peningkatan pada data validasi mulai terbatas. Model mulai lebih menyesuaikan diri pada data training dibandingkan mampu melakukan generalisasi terhadap data baru. Meskipun itu, overfitting yang terjadi tidak tergolong parah.

	karena validation loss tidak mengalami kenaikan drastis, melainkan hanya stabil pada kisaran tertentu. Hal ini mengindikasikan bahwa model masih cukup stabil, namun belum mencapai performa optimal dalam melakukan generalisasi.
Temuan	<i>Uraikan temuan khusus (jika ada) pada proses latih, misal: ternyata terjadi overfitting atau underfitting.</i> <i>Proses latih-nya dilanjutkan dengan hyperparameter tuning</i> Berdasarkan hasil pelatihan dan evaluasi model, ditemukan bahwa LSTM mengalami overfitting, ditunjukkan oleh nilai error yang tinggi (MAE: 372.4816, RMSE: 541.3690) serta R^2 Score yang lebih rendah (0.868582) dibandingkan model lainnya. Hal ini menunjukkan bahwa LSTM kurang mampu melakukan generalisasi pada data uji. Sementara itu, Random Forest Regression dan XGBoost Regression menunjukkan performa yang sangat baik dengan error rendah dan R^2 Score mendekati 1, sehingga tidak terindikasi overfitting yang signifikan. Sebagai tindak lanjut, pelatihan dilanjutkan dengan hyperparameter tuning untuk meningkatkan performa model, khususnya LSTM, agar dapat mengurangi overfitting dan meningkatkan kemampuan generalisasi