

Laporan Akhir Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024- C
Ketua	Rafael Hartono (24031554166)
Anggota 1	Athiyyatus Salisah (24031554223)
Anggota 2	Nurul Aini (24031554060)
URL Github	https://github.com/rafaelhartono8/166_060_223_Machine-Learning

Informasi Umum Proyek


Judul	Analisis Perbandingan Algoritma Random Forest Regression dan XGBoost untuk Prediksi Daya Panel Surya Berdasarkan Data Meteorologi pada Wilayah 3T di Indonesia
Topik	Energi
Pilihan Rumusan Masalah	3.8 Minimnya Pemanfaatan IoT dan AI untuk Ekspansi Elektrifikasi di Daerah 3T
Revisi?	Ya / Tidak

Pendahuluan

Latar belakang (≥ 250 kata)	Indonesia memiliki target mencapai Net Zero Emission melalui peningkatan pemanfaatan energi baru terbarukan sebagai upaya mengurangi ketergantungan terhadap energi fosil dan menekan emisi gas rumah kaca[1]. salah satu sumber energi terbarukan yang memiliki potensi besar untuk dikembangkan adalah energi surya. Hal ini didukung oleh letak geografis Indonesia yang berada di wilayah khatulistiwa sehingga memperoleh penyinaran matahari yang relatif tinggi[2]. Potensi tersebut menjadikan energi surya sebagai salah satu alternatif dalam mendukung ketahanan energi nasional, khususnya pada wilayah Terdepan, Terluar, dan Tertinggal (3T) yang masih menghadapi keterbatasan akses listrik dan infrastruktur energi[3]. Meskipun memiliki potensi yang besar, perencanaan pemasangan panel surya pada wilayah 3T memerlukan Analisis yang matang untuk memastikan sistem yang dibangun mampu menghasilkan daya sesuai kebutuhan. Salah satu tantangan utama adalah belum tersedianya informasi yang akurat mengenai potensi daya panel surya pada lokasi yang akan dipasang. Tanpa adanya estimasi proses perencanaan kapasitas sistem, pemilihan teknologi, serta analisis kelayakan investasi berisiko menghasilkan keputusan yang kurang optimal. Oleh karena itu, diperlukan metode yang mampu mengestimasi potensi daya panel surya sebelum sistem dipasang. Potensi daya panel surya dipengaruhi oleh berbagai faktor meteorologi, seperti radiasi matahari, suhu udara, dan ketinggian matahari[4]. Namun, tingkat pengaruh masing-masing faktor terhadap daya yang dihasilkan belum tentu sama. Identifikasi faktor-faktor yang paling berpengaruh menjadi penting untuk meningkatkan akurasi model estimasi serta memberikan pemahaman yang lebih baik mengenai karakteristik pembangkitan energi surya pada wilayah 3T. Perkembangan machine learning memungkinkan untuk membangun model yang mampu mempelajari hubungan antara data meteorologi dan daya keluaran panel surya. Dalam penelitian ini, algoritma Random Forest Regression dan XGBoost digunakan untuk membangun model estimasi daya panel surya pada wilayah 3T di Indonesia.
--------------------------------	---

	Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk mengembangkan model estimasi daya panel surya berdasarkan data meteorologi pada wilayah 3T di Indonesia, mengidentifikasi faktor meteorologi yang paling berpengaruh terhadap daya panel surya, serta membandingkan kinerja algoritma Random Forest Regression dan XGBoost untuk menentukan model terbaik dalam mengestimasi potensi daya panel surya sebelum pemasangan.												
Rumusan masalah dan tujuan	<i>Tuliskan rumusan dan tujuan permasalahan di sini..</i> Rumusan Masalah yang dapat kita ambil dari Latar belakang diatas adalah sebagai berikut: 1. Bagaimana membangun model yang mampu mengestimasi potensi daya panel surya pada wilayah 3T berdasarkan data meteorologi sebelum panel surya dipasang? 2. Faktor meteorologi apa saja yang paling berpengaruh terhadap estimasi daya panel surya pada wilayah 3T? 3. Bagaimana perbandingan kinerja algoritma Random Forest Regression dan XGBoost dalam mengestimasi daya panel surya berdasarkan data meteorologi pada wilayah 3T? 4. Algoritma manakah yang memberikan performa terbaik dalam mengestimasi daya panel surya pada wilayah 3T? Tujuan: 1. Mengembangkan model estimasi daya panel surya pada wilayah 3T berdasarkan data meteorologi. 2. Mengidentifikasi faktor meteorologi yang paling berpengaruh terhadap daya panel surya. 3. Menganalisis dan membandingkan kinerja algoritma Random Forest Regression dan XGBoost dalam mengestimasi daya panel surya. 4. Menentukan algoritma dengan performa terbaik berdasarkan hasil evaluasi model.												
Metodologi													
Ringkasan dataset	Dataset yang digunakan dalam penelitian ini merupakan data meteorologi dan estimasi daya panel surya yang diperoleh melalui proses scraping dari PVGIS (Photovoltaic Geographical Information System) pada beberapa wilayah 3T (Tertinggal, Terdepan, dan Terluar) di Indonesia. Dataset terdiri dari data time series dengan interval per jam yang mencakup parameter meteorologi yang berpengaruh terhadap kinerja panel surya. Variabel yang digunakan meliputi Solar Irradiance (G(i)), Sun Height, Temperature (T2m), Wind Speed (WS10m), dan City sebagai representasi lokasi pengamatan. Variabel target (output) yang digunakan adalah Power Output (P) yang menunjukkan estimasi daya keluaran panel surya dalam satuan Watt (W). Dan memiliki jumlah data sebanyak 2439968 baris yang merupakan data periode tahun 2015 hingga 2020 . Berikut merupakan Variabel yang digunakan: <table><caption>Tabel 1. Variabel Data</caption><thead><tr><th>Nama Atribut</th><th>Deskripsi</th><th>Type Data</th><th>Satuan</th></tr></thead><tbody><tr><td>SolarIrradiance</td><td>Intensitas radiasi matahari yang diterima permukaan panel surya.</td><td>Float</td><td>W/m²</td></tr><tr><td>SunHeight</td><td>Ketinggian posisi matahari terhadap horizon pada waktu tertentu</td><td>Float</td><td>Derajat (°)</td></tr></tbody></table>	Nama Atribut	Deskripsi	Type Data	Satuan	SolarIrradiance	Intensitas radiasi matahari yang diterima permukaan panel surya.	Float	W/m ²	SunHeight	Ketinggian posisi matahari terhadap horizon pada waktu tertentu	Float	Derajat (°)
Nama Atribut	Deskripsi	Type Data	Satuan										
SolarIrradiance	Intensitas radiasi matahari yang diterima permukaan panel surya.	Float	W/m ²										
SunHeight	Ketinggian posisi matahari terhadap horizon pada waktu tertentu	Float	Derajat (°)										

	Temperature	Suhu udara pada lokasi pengamatan	Float	°C
	WindSpeed	Suhu udara pada lokasi pengamatan	Float	m/s
	PowerOutput	Estimasi daya listrik yang dihasilkan panel surya. Atribut digunakan sebagai target prediksi.	Float	Watt (W)
	City	Nama kota lokasi pengambilan data panel surya di Indonesia	Object/String	-



	penggabungan data dari beberapa lokasi. Hasil akhir tahap ini adalah dataset yang lebih terstruktur dan konsisten. 3. Data Splitting Dataset dibagi menjadi dua bagian yaitu data latih (training set) dan data uji (testing set), misalnya dengan rasio 80:20. Data training digunakan untuk membangun model, sedangkan data testing digunakan untuk mengevaluasi kemampuan generalisasi model terhadap data baru yang belum pernah dilihat sebelumnya. 4. Feature Engineering & Correlation Pada tahap ini dilakukan transformasi dan analisis fitur. Proses meliputi encoding variabel kategorik (misalnya kota), normalisasi atau standardisasi data, serta analisis korelasi untuk melihat hubungan antar variabel. Selain itu dilakukan seleksi fitur untuk memilih variabel yang paling berpengaruh terhadap daya panel surya sehingga model menjadi lebih optimal. 5. Random Forest Regression Tahap ini membangun model menggunakan algoritma Random Forest Regression. Model ini bekerja dengan menggabungkan banyak decision tree untuk menghasilkan prediksi yang lebih stabil dan akurat. Model dilatih menggunakan data training yang telah diproses sebelumnya. 6. XGBoost Regression Pada tahap ini digunakan algoritma XGBoost Regression sebagai pembanding. XGBoost bekerja dengan metode boosting yang membangun model secara bertahap untuk memperbaiki error dari model sebelumnya, sehingga biasanya memiliki performa yang sangat baik dalam masalah regresi. 7. Evaluasi Model Kedua model dievaluasi menggunakan data testing. Evaluasi dilakukan dengan metrik seperti MAE (Mean Absolute Error), RMSE (Root Mean Squared Error), dan R² Score untuk mengukur tingkat kesalahan dan akurasi model dalam melakukan prediksi. 8. Pemilihan Model Terbaik Hasil evaluasi dari Random Forest dan XGBoost dibandingkan untuk menentukan model terbaik. Model dengan nilai error paling rendah dan nilai R² paling tinggi dipilih sebagai model final dalam penelitian. 9. Estimasi Potensi Daya Panel Surya Model terbaik digunakan untuk mengestimasi potensi daya panel surya berdasarkan data meteorologi pada wilayah 3T. Hasil estimasi ini dapat digunakan sebagai dasar dalam perencanaan pemasangan panel surya, analisis kelayakan, serta perhitungan potensi energi. 10. Selesai
Proses <i>wrangling</i>	<i>Tuliskan proses wrangling data yang tim lakukan dan hasilnya seperti apa. Potongan code yang relevan saja boleh dicantumkan di sini.</i> Data Wrangling merupakan proses persiapan dan transformasi data agar siap digunakan pada tahap analisis dan pemodelan. Pada proyek kami, data yang digunakan merupakan data meteorologi dan daya keluaran panel surya dari beberapa wilayah 3T di Indonesia dengan total 2.209.536 baris data dan 8 atribut, yaitu Datetime, PowerOutput, SolarIrradiance, SunHeight, Temperature, WindSpeed, Int, dan City. Berikut merupakan beberapa proses wrangling yang kami gunakan.

1. Pemeriksaan Struktur Data

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2209536 entries, 0 to 2209535
Data columns (total 8 columns):
#   Column          Dtype
---  -
0   Datetime        object
1   PowerOutput     float64
2   SolarIrradiance float64
3   SunHeight       float64
4   Temperature     float64
5   WindSpeed       float64
6   Int             float64
7   City            object
dtypes: float64(6), object(2)
memory usage: 134.9+ MB
```

Gambar 2. Code Pemeriksaan Struktur Data

Tahap awal dilakukan dengan memeriksa struktur dataset menggunakan fungsi `df.info()`. Hasil pemeriksaan menunjukkan bahwa dataset terdiri dari 2.209.536 observasi dengan 8 atribut. Sebanyak 6 atribut bertipe numerik (`float64`) yaitu `PowerOutput`, `SolarIrradiance`, `SunHeight`, `Temperature`, `WindSpeed`, dan `Int`, sedangkan atribut `Datetime` dan `City` bertipe `object`.

2. Cek Missing Value

```
df.isna().sum()

PowerOutput    0
SolarIrradiance 0
SunHeight      0
Temperature     0
WindSpeed      0
Int            0
City           0
dtype: int64
```

Gambar 3. Code Missing Value

Pengecekan missing value dilakukan menggunakan fungsi `df.isna().sum()`. Hasil pemeriksaan menunjukkan bahwa seluruh atribut memiliki nilai missing value sebanyak 0. Yang berarti, tidak diperlukan proses penanganan missing value karena dataset telah lengkap dan siap digunakan untuk tahap berikutnya.

3. Penghapusan Atribut Datetime

```
Delete Datetime

df = df.drop('Datetime', axis=1)
df
```

	PowerOutput	SolarIrradiance	SunHeight	Temperature	WindSpeed	Int	City
0	35.86	62.89	10.65	26.17	3.10	0.0	Simeulue
1	108.00	153.56	24.20	26.48	3.24	0.0	Simeulue
2	247.85	321.80	37.31	26.55	3.38	0.0	Simeulue
3	281.46	363.02	49.43	26.98	3.17	0.0	Simeulue
4	278.47	362.80	59.34	27.11	2.83	0.0	Simeulue

Gambar 3. Code Penghapusan Atribut Datetime

Pada tahap selanjutnya dilakukan penghapusan atribut `Datetime` menggunakan fungsi `drop()`. Atribut ini dihapus karena tidak digunakan secara langsung dalam proses pemodelan yang dilakukan pada penelitian ini. Penghapusan atribut dilakukan untuk mengurangi kompleksitas data dan memastikan bahwa model hanya menggunakan variabel yang relevan dalam proses prediksi. Setelah atribut `Datetime` dihapus, dataset terdiri dari tujuh atribut, yaitu `PowerOutput`, `SolarIrradiance`, `SunHeight`, `Temperature`, `WindSpeed`, `Int`, dan `City`.

4. Analisis Statistik Deskriptif

```
df.describe()
```

	PowerOutput	SolarIrradiance	SunHeight	Temperature	WindSpeed	Int
count	2.209536e+06	2.209536e+06	2.209536e+06	2.209536e+06	2.209536e+06	2209536.0
mean	1.179557e+02	1.584686e+02	2.048801e+01	2.406028e+01	1.855420e+00	0.0
std	1.860768e+02	2.447131e+02	2.640910e+01	4.316626e+00	2.089378e+00	0.0
min	0.000000e+00	0.000000e+00	-7.380000e+00	3.520000e+00	0.000000e+00	0.0
25%	0.000000e+00	0.000000e+00	0.000000e+00	2.236000e+01	6.200000e-01	0.0
50%	2.500000e-01	6.540000e+00	3.400000e-01	2.504000e+01	1.240000e+00	0.0
75%	1.672100e+02	2.268500e+02	4.241000e+01	2.692000e+01	2.480000e+00	0.0
max	8.348900e+02	1.123690e+03	8.994000e+01	4.120000e+01	3.779000e+01	0.0

Gambar 4. Code Statistik Deskriptif

Hasil analisis menunjukkan bahwa dataset terdiri dari 2.209.536 observasi untuk setiap variabel numerik, yaitu PowerOutput, SolarIrradiance, SunHeight, Temperature, WindSpeed, dan Int. Nilai rata-rata (*mean*) PowerOutput sebesar 117,96 W dengan nilai minimum 0 W dan nilai maksimum 834,89 W. Hal ini menunjukkan bahwa daya keluaran panel surya bervariasi cukup besar, mulai dari kondisi tidak menghasilkan daya hingga menghasilkan daya maksimum sebesar 834,89 W. Variabel SolarIrradiance memiliki rata-rata sebesar 158,47 W/m² dengan nilai maksimum mencapai 1.123,69 W/m². Variabel ini menunjukkan tingkat intensitas radiasi matahari yang diterima panel surya dan menjadi salah satu faktor utama yang memengaruhi produksi energi listrik. Variabel SunHeight memiliki rata-rata sebesar 40,49° dengan nilai maksimum 89,94°. Nilai ini menunjukkan variasi posisi matahari selama periode pengamatan. Variabel Temperature memiliki rata-rata sebesar 24,06°C dengan rentang nilai antara 3,52°C hingga 41,20°C. Sementara itu, WindSpeed memiliki rata-rata sebesar 1,86 m/s dengan nilai maksimum 37,79 m/s.

5. Penghapusan Variabel Int

```
df = df.drop('Int', axis=1)
df
```

	PowerOutput	SolarIrradiance	SunHeight	Temperature	WindSpeed	City
0	35.86	62.89	10.65	26.17	3.10	Simeulue
1	108.00	153.56	24.20	26.48	3.24	Simeulue
2	247.85	321.80	37.31	26.55	3.38	Simeulue
3	281.46	363.02	49.43	26.98	3.17	Simeulue
4	278.47	362.80	59.34	27.11	2.83	Simeulue


Gambar 4. Code Penghapusan Variabel Int

Berdasarkan hasil analisis statistik deskriptif, atribut Int memiliki nilai minimum, maksimum, rata-rata (*mean*), dan standar deviasi (*standard deviation*) sebesar 0. Hal ini menunjukkan bahwa seluruh data pada atribut tersebut memiliki nilai yang sama (konstan) sehingga tidak mengandung variasi informasi.

Setelah proses penghapusan dilakukan, jumlah atribut pada dataset berkurang dari 7 atribut menjadi 6 atribut, yaitu PowerOutput, SolarIrradiance, SunHeight, Temperature, WindSpeed, dan City.


Penghapusan atribut yang tidak relevan bertujuan untuk menyederhanakan struktur data, mengurangi kompleksitas pemodelan, serta memastikan bahwa model hanya menggunakan atribut yang berpotensi memberikan kontribusi terhadap proses prediksi daya panel surya.

Proses rekayasa fitur	1. Label Encoding pada Atribut City Pada tahap rekayasa fitur (<i>feature engineering</i>), dilakukan transformasi terhadap atribut City yang bertipe kategorikal menjadi data numerik menggunakan metode Label Encoding. Transformasi ini diperlukan karena algoritma Random Forest Regression dan XGBoost Regression, tidak dapat memproses data dalam bentuk teks secara langsung[5]. Proses transformasi dilakukan menggunakan kelas LabelEncoder dari pustaka Scikit-Learn. Label encoder memberikan representasi numerik yang unik untuk setiap kategori kota yang terdapat pada dataset. Proses encoding diterapkan pada data latih (<i>training set</i>) menggunakan fungsi <code>fit_transform()</code>, kemudian hasil pemetaan yang sama diterapkan pada data uji (<i>testing set</i>) menggunakan fungsi <code>transform()</code>. Penerapan <code>fit_transform()</code> hanya dilakukan pada data latih untuk membangun pemetaan kategori ke nilai numerik, sedangkan data uji menggunakan <code>transform()</code> agar konsisten dengan pemetaan yang telah dibentuk pada data latih. Pendekatan ini dilakukan untuk menghindari <i>data leakage</i> yang dapat mempengaruhi hasil evaluasi model. Melalui proses ini, setiap nama kota pada atribut City berhasil diubah menjadi numerik sehingga dapat digunakan sebagai fitur input pada proses pelatihan dan pengujian model machine learning. 2. Feature Selection menggunakan ANOVA ANOVA (<i>Analysis of Variance</i>) digunakan untuk mengevaluasi apakah perbedaan nilai target pada beberapa kategori suatu fitur terjadi secara signifikan atau hanya karena variasi acak. Fitur yang memiliki nilai p-value lebih kecil dari tingkat signifikansi (0,05) dianggap memiliki hubungan yang signifikan dengan variabel target dan layak dipertahankan dalam proses pemodelan[6]. Pada tahap rekayasa fitur dilakukan uji Analysis of Variance (ANOVA) untuk mengetahui apakah variabel kategorikal City memiliki pengaruh yang signifikan terhadap variabel target PowerOutput. Uji ANOVA digunakan untuk membandingkan rata-rata nilai PowerOutput pada beberapa kelompok kota. Hipotesis yang digunakan adalah: • H_0 : Tidak terdapat perbedaan rata-rata PowerOutput antar kota. • H_1 : Terdapat perbedaan rata-rata PowerOutput antar kota. Pengujian dilakukan menggunakan model <i>Ordinary Least Squares</i> (OLS) dan tabel ANOVA tipe II. Hasil pengujian menunjukkan nilai F-statistic sebesar 4387,33 dan p-value sebesar 0,00000. Karena nilai p-value lebih kecil dari tingkat signifikansi 0,05, maka hipotesis nol (H_0) ditolak. Hal ini menunjukkan bahwa terdapat perbedaan rata-rata PowerOutput yang signifikan antar kota. Dengan demikian, variabel City memiliki pengaruh yang signifikan terhadap daya keluaran panel surya dan layak dipertahankan sebagai fitur dalam proses pemodelan menggunakan algoritma Random Forest Regression dan XGBoost Regression. 3. Reduksi dimensi menggunakan PCA Pada tahap rekayasa fitur dilakukan Principal Component Analysis (PCA) untuk mereduksi dimensi data numerik tanpa menghilangkan sebagian besar informasi yang terkandung dalam dataset. Sebelum proses PCA dilakukan, seluruh fitur numerik terlebih dahulu dinormalisasi menggunakan metode StandardScaler agar memiliki skala yang seragam. Selanjutnya dilakukan ekstraksi komponen utama menggunakan metode PCA terhadap data yang telah dinormalisasi. Penentuan jumlah komponen utama dilakukan berdasarkan Kaiser Criterion, yaitu memilih komponen yang memiliki nilai
------------------------------	--

	eigenvalue lebih besar dari 1. Hasil ekstraksi PCA ditunjukkan pada Tabel berikut. Tabel 2. Hasil ekstraksi PCA <table border="1"> <thead> <tr> <th>Komponen Utama</th><th>Eigenvalue</th></tr> </thead> <tbody> <tr> <td>PC1</td><td>2.0991</td></tr> <tr> <td>PC2</td><td>1.1115</td></tr> <tr> <td>PC3</td><td>0.6033</td></tr> <tr> <td>PC4</td><td>0.1862</td></tr> </tbody> </table> Berdasarkan hasil tersebut, diperoleh dua komponen utama yang memiliki nilai eigenvalue lebih besar dari 1, yaitu PC1 dan PC2. Oleh karena itu, jumlah komponen yang dipertahankan adalah sebanyak 2 komponen. Proses reduksi dimensi ini berhasil mengubah beberapa variabel numerik menjadi dua komponen utama yang mampu merepresentasikan sebagian besar variasi data. Hasil transformasi PCA menghasilkan dua fitur baru, yaitu PC1 dan PC2, yang selanjutnya dapat digunakan sebagai masukan pada proses pemodelan.	Komponen Utama	Eigenvalue	PC1	2.0991	PC2	1.1115	PC3	0.6033	PC4	0.1862
Komponen Utama	Eigenvalue										
PC1	2.0991										
PC2	1.1115										
PC3	0.6033										
PC4	0.1862										
Temuan	Secara keseluruhan, hasil analisis menunjukkan bahwa SolarIrradiance, SunHeight, dan City merupakan faktor yang paling berpengaruh terhadap PowerOutput panel surya. Sementara itu, Temperature dan WindSpeed memberikan kontribusi yang lebih kecil. Temuan ini mengindikasikan bahwa kondisi penyinaran matahari dan karakteristik lokasi menjadi faktor utama yang menentukan potensi produksi energi surya pada wilayah 3T di Indonesia.										
Hasil dan Pembahasan											
Hasil data eksplorasi	<i>Uraikan hasil eksplorasi data. Gunakan visualisasi-visualisasi untuk menunjukkan informasi kunci yang ingin diangkat.</i> 										


Gambar 5. Distribusi antar Tiap Fitur Numerik

Pada scatter plot Gambar 2 menunjukkan bahwa fitur radiasi matahari (solar irradiantes) memiliki korelasi yang paling kuat dengan terhadap daya listrik yang dihasilkan.



Gambar 6. Korelasi Matriks Pearson

Pada korelasi matriks gambar 3, menunjukkan adanya multikorelasi antara SolarIrradiance dan Sun Height oleh karena itu dibutuhkan reduksi dimensi




Gambar 7. Boxplot Distribusi Power Output Berdasarkan kota

Pada gambar 4, menunjukkan bahwa distribusi dari tiap kota itu berbeda beda dan tidak sama. Hal ini mendukung hasil dari uji anova

Tabel 3. Hasil Uji Anova

	sum_sq	df	F	PR(>F)
City	5.646665e+09	41	4387.334835	0.0000
Residual	5.548658e+10	1767586	NaN	NaN



Gambar 8. Biplot PCA

Berdasarkan aturan keiser meiyer rule dengan eigen value > 1 ini mendapatkan 2 pc yang mampu menjelaskan sekitar 80% dari seluruh data.

Pada gambar 5, menunjukan bahwa PC 1 condong ke *solarirradiance* dan *sunheight* dimana semakin kekanan bawah maka akan semakin tinggi power outputnya

Narasikan proses latih dan validasi yang telah Anda lakukan, lalu hubungkan dengan hasil metrik yang didapat.


Hasil eksperimen

Pada tahap eksperimen, data meteorologi yang digunakan dalam penelitian diperoleh melalui proses scraping dari platform PVGIS. Data tersebut mencakup berbagai parameter yang berpengaruh terhadap kinerja panel surya, seperti PowerOutput, SolarIrradiance, SunHeight, Temperature, dan WindSpeed,. Sebelum digunakan dalam proses pemodelan, Dataset hasil scraping PVGIS dilakukan data wrangling terlebih dahulu, kemudian dibagi menjadi data training sebesar 80% dan data testing sebesar 20%. Pada data training dilakukan proses encoding variabel kota, analisis korelasi, seleksi fitur, standardisasi, dan reduksi dimensi menggunakan PCA. Selanjutnya data training digunakan untuk melatih model Random Forest Regression dan XGBoost Regression. Setelah proses pelatihan selesai, data testing diproses menggunakan encoder, scaler, dan PCA yang diperoleh dari data training. Data testing kemudian digunakan untuk mengevaluasi kemampuan model dalam mengestimasi daya panel surya pada data yang belum pernah dilihat sebelumnya. Berikut adalah Hasil Evaluasi Pemodelan:

Tabel 4. Hasil Evaluasi


Model	MAE Tes	RMSE Tes	R ² Tes
Random Forest Regression	14,50	28,96	0,9759
XGBoost Regression	15,52	30,08	0.9740

Hasil evaluasi dapat menunjukkan bahwa kedua model memiliki performa yang sangat baik dalam mengestimasi daya panel surya berdasarkan data meteorologi. Random Forest Regression menghasilkan nilai MAE sebesar 14,50 , RMSE sebesar 28,96 , dan R^2 sebesar 0,9759. Sementara itu, XGBoost Regression menghasilkan nilai MAE sebesar 15,52, RMSE sebesar 30,08, dan R^2 sebesar 0,9740. Meskipun XGBoost memiliki nilai MAE yang sedikit lebih rendah, Random Forest menghasilkan nilai RMSE yang lebih kecil dan nilai R^2 yang lebih tinggi. Hal ini menunjukkan bahwa Random Forest memiliki kemampuan yang lebih baik dalam meminimalkan kesalahan prediksi yang besar serta mampu menjelaskan variasi data dengan lebih baik. Oleh karena itu, Random Forest Regression dipilih sebagai model terbaik dalam penelitian ini.



Gambar 9. Analisis Training


Pada gambar 9 membandingkan akurasi dari data training dan data test. Pada perbandingan R^2 menunjukan bahwa akurasi data training dan data test tidak ada perbedaan yang terlalu signifikan pada model Random Forest dan XGBoost. Yang menunjukan bahwa model mengalami overfitting. Pada perbandingan RMSE menunjukan bahwa model Random Forest mampu mendapatkan error yang lebih kecil meskipun sedikit overfitting, Sedangkan XGBoost tidak terlalu mudah overfitting meskipun memiliki error yang lebih tinggi.



Gambar 10. Distribusi Error

Pada plot distribusi menunjukkan bahwa XGBoost memiliki kesalahan tebakan yang jauh lebih tinggi dibandingkan Random Forest yang menyebabkan turunnya akurasi XGBoost meskipun lebih tahan dari overfitting.

Setelah dilakukan evaluasi menggunakan metrik MAE, RMSE, dan R^2 , langkah selanjutnya adalah memvisualisasikan hasil prediksi model terhadap data aktual. Visualisasi Actual vs Prediction digunakan untuk melihat sejauh mana model mampu mengikuti pola data sebenarnya. Berikut adalah hasil Visualisasinya:



Gambar 11. Perbandingan Aktual dan Prediksi

Pada perbandingan aktual dan prediksi gambar 11, menunjukkan bahwa model Random Forest dan XGBoost mampu memprediksi daya keluaran panel surya dengan sangat baik. Hal ini terlihat dari sebagian besar titik prediksi yang berada di sekitar garis diagonal merah sebagai garis prediksi ideal.

Kesimpulan dan Saran

Kesimpulan

Uraikan bagaimana proyek Anda dapat berkontribusi pada penyelesaian masalah yang telah Anda rumuskan.

Temuan apakah yang dapat digunakan oleh masyarakat?

Nilai R^2 Random Forest sebesar 0,9759 dan XGBoost sebesar 0,974 menunjukkan bahwa kedua model mampu menjelaskan lebih dari 97% variasi data aktual. Pada plot ini menunjukkan penyebab akurasi XGBoost turun dan tingginya tingkat error, karena XGBoost sedikit kesulitan menangkap pola untuk power output 0 hingga 100 Watt dan 500 hingga 800 Watt. Meskipun terdapat beberapa penyimpangan pada nilai daya yang tinggi, secara keseluruhan kedua model menghasilkan prediksi yang mendekati nilai sebenarnya. Berdasarkan hasil tersebut, Random Forest memiliki performa sedikit lebih baik dibandingkan XGBoost, meskipun perbedaannya relatif kecil.

Dengan kemampuan mengestimasi daya listrik yang dapat dihasilkan oleh panel surya sebelum pemasangan. Model Random Forest yang kami hasilkan dapat membantu investor atau perencana wilayah dalam mengestimasi *Return of Investment* dan lama kembalinya modal yang diinvestasikan.

	Secara tidak langsung penelitian ini membantu meningkatkan penjualan panel surya dan meningkatkan perekonomian pada wilayah 3T karena dengan energi terbarukan yang murah pada area 3T mampu mengundang industri yang dapat meningkatkan lapangan kerja.
Saran	<i>Tuliskan saran-saran untuk penelitian berikutnya</i> Pada penelitian selanjutnya kami menyarankan untuk pembuatan model yang mampu mengestimasi tiap fitur (SolarIrradiance, SunHeight, Temperature, WindSpeed) dalam time series seperti metode arima, sarima, dan LSTM agar dapat dikombinasikan dengan model kami. Dengan demikian akan kombinasi model ini dapat mengestimasi juga berapa total listrik yang dihasilkan dalam bulanan dan tahunan sebelum panel surya terpasang. Prediksi dengan pendekatan geospasial yang mampu memetakan power output yang bisa dihasilkan tiap area juga menarik dalam penentuan lokasi terbaik dalam penempatan panel surya.
Daftar Pustaka	
Daftar Pustaka	<i>Referensi-referensi yang digunakan dalam pengerjaan proyek. Gunakan Mendeley / Zotero.</i> [1] Y. I. Siregar, "Pathways towards net-zero emissions in Indonesia's energy sector," <i>Energy</i>, vol. 308, p. 133014, Nov. 2024, doi: 10.1016/j.energy.2024.133014. [2] E. P. Laksana <i>et al.</i>, "Potential Usage of Solar Energy as a Renewable Energy Source in Petukangan Utara, South Jakarta," <i>JRE</i>, vol. 17, no. 4, Dec. 2021, doi: 10.17529/jre.v17i4.22538. [3] A. B. Setyowati, "Mitigating Energy Poverty: Mobilizing Climate Finance to Manage the Energy Trilemma in Indonesia," <i>Sustainability</i>, vol. 12, no. 4, p. 1603, Feb. 2020, doi: 10.3390/su12041603. [4] O. Bamisile, C. Acen, D. Cai, Q. Huang, and I. Staffell, "The environmental factors affecting solar photovoltaic output," <i>Renewable and Sustainable Energy Reviews</i>, vol. 208, p. 115073, Feb. 2025, doi: 10.1016/j.rser.2024.115073. [5] C. Herdian, A. Kamila, and I. G. Agung Musa Budidarma, "Studi Kasus Feature Engineering Untuk Data Teks: Perbandingan Label Encoding dan One-Hot Encoding Pada Metode Linear Regresi," <i>Technologia</i>, vol. 15, no. 1, p. 93, Jan. 2024, doi: 10.31602/tji.v15i1.13457. [6] T. N. Annisa, J. Jasmir, and N. Nurhadi, "Comparison of ANOVA and Chi-Square Feature Selection Methods to Improve Machine Learning Performance in Anemia Classification," <i>J. Tek. Inform. (JUTIF)</i>, vol. 6, no. 4, pp. 1925–1940, Aug. 2025, doi: 10.52436/1.jutif.2025.6.4.5017.