

Proposal Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Rafael Hartono (24031554166)
Anggota 1	Athiyyatus Salisah (24031554223)
Anggota 2	Nurul Aini (24031554060)
URL Github	https://github.com/rafaelhartono8/060_223_166-Data-Mining-Project

Informasi Umum Proyek

Judul	<i>Analisis Perbandingan Algoritma Random Forest Regression dan XGBoost untuk Prediksi Daya Panel Surya Berdasarkan Data Meteorologi di Indonesia</i>
Topik	<i>Energi</i>
Pilihan Rumusan Masalah	3.8 Minimnya Pemanfaatan IoT dan AI untuk Ekspansi Elektrifikasi di Daerah 3T
Revisi?	<i>Ya / Tidak</i>


Deskripsi Rumusan masalah	<i>Tuliskan rationale atau significance atau background dari permasalahan yang diangkat.</i> <i>Apa yang mendesak dari permasalahan tersebut? Mengapa permasalahan tersebut belum terselesaikan? Apa tantangan penyelesaian masalah tersebut?</i> Deskripsi Indonesia memiliki target dalam mencapai <i>Net Zero Emission</i> melalui transisi energi terbarukan, di mana energi surya menjadi instrumen penting karena lokasinya yang berada di garis khatulistiwa. Namun, transisi pembangkit energi surya memiliki tantangan fluktuasi daya akibat cuaca yang dapat mengganggu stabilitas jaringan listrik. Permasalahan ini menjadi sangat krusial bagi daerah 3T (Tertinggal, Terdepan, Terluar) yang mengandalkan sistem listrik gabungan antara PLN dan energi surya (<i>microgrid</i>) atau mandiri tanpa cadangan PLN (<i>off-grid</i>). Di wilayah ini, ketidakpastian output daya bukan sekadar masalah efisiensi, melainkan risiko teknis yang dapat menyebabkan pemborosan siklus baterai hingga pemadaman listrik secara total. Saat ini, pemanfaatan AI untuk memprediksi daya masih sangat minim di daerah 3T. Sebagian besar operasional masih bersifat reaktif terhadap perubahan cuaca. Dibutuhkan sistem manajemen energi cerdas yang dapat memprediksi berapa daya yang akan dihasilkan beberapa jam ke depan untuk mengatur strategi pengisian baterai atau mengatur penggunaan beban secara otomatis. Tanpa prediksi yang akurat, ketersediaan energi yang stabil di daerah terpencil akan sulit tercapai. Hingga kini, tantangan utama adalah karakteristik iklim tropis Indonesia yang memiliki dinamika awan sangat cepat dan kelembapan tinggi, yang sangat berbeda dengan dataset wilayah subtropis. Selain itu, mengolah <i>big data</i> dari berbagai kota di Indonesia membutuhkan algoritma yang tidak hanya presisi secara akurasi, tetapi juga
---------------------------	---

	efisien secara komputasi agar dapat diimplementasikan pada perangkat IoT di masa depan. Rumusan Masalah 1. Bagaimana pengaruh variabel meteorologi tropis yang dinamis terhadap akurasi estimasi daya panel surya di berbagai wilayah Indonesia? 2. Sejauh mana efektivitas algoritma Random Forest Regression dibandingkan dengan XGBoost dalam menghasilkan prediksi yang presisi pada dataset skala besar? 3. Algoritma manakah yang memiliki performa akurasi dan efisiensi waktu komputasi terbaik?
Tujuan penelitian (Objectives)	<i>Tuliskan tahapan-tahapan, atau target penyelesaian</i> 1. Menganalisis korelasi antara variabel meteorologi khas iklim tropis Indonesia terhadap output daya listrik panel surya. 2. Membangun dan menguji model prediksi menggunakan algoritma Random Forest dan XGBoost. 3. Membandingkan performa kedua algoritma dengan evaluasi regresi untuk menemukan akurasi terbaik. 4. Mengevaluasi efisiensi komputasi <i>training time</i> dan penggunaan sumber daya dari masing-masing model untuk menentukan algoritma yang paling layak diimplementasikan pada sistem manajemen energi cerdas berbasis IoT di daerah 3T.
Referensi penelitian	<i>Tuliskan 3-5 penelitian terdahulu yang menjadi inspirasi pengerjaan proyek Anda. Penelitian terdahulu wajib: jurnal internasional dengan penerbit selain MDPI. Jurnal terbit setidaknya di tahun 2020. Tuliskan <u>link-link DOI-nya</u> saja cukup.</i> [1] 10.1109/ACCESS.2025.3579755 [2] 10.1109/ACCESS.2024.3437191 [3] 10.1109/ACCESS.2026.3670286 [4] 10.1109/ACCESS.2025.3574093 [5] 10.1109/ACCESS.2024.3496120

Informasi Detil Dataset

Sumber dataset	Dataset yang digunakan pada penelitian ini diperoleh melalui proses scraping data dari layanan API resmi PVGIS (Photovoltaic Geographical Information System) milik European Commission Joint Research Centre (JRC). API yang digunakan adalah layanan non-interactive service PVGIS 5.2 yang dapat diakses melalui link ini. Proses pengambilan data dilakukan secara otomatis menggunakan bahasa pemrograman Python dengan bantuan library requests dan pandas. Data diambil melalui API PVGIS untuk beberapa kota di Indonesia dengan parameter koordinat lintang dan bujur (latitude dan longitude) masing-masing kota. Data yang diambil mencakup periode tahun 2015 hingga 2020 dengan resolusi data per jam (hourly data). Data hasil scraping yaitu sebanyak 2439968 baris, 8 kolom, dan ukuran file sebesar 122.12 MB.
Deskripsi awal fitur dataset	<i>Tuliskan nama-nama atribut dataset berikut dengan: deskripsi dan tipe data nya.</i>

	Dataset yang digunakan dalam proyek ini terdiri dari beberapa atribut yang berkaitan dengan kondisi lingkungan dan estimasi energi panel surya. Berikut merupakan deskripsi masing-masing atribut beserta tipe datanya: <table><thead><tr><th>Nama Atribut</th><th>Deskripsi</th><th>Tipe Data</th></tr></thead><tbody><tr><td>Datetime</td><td>Tanggal dan waktu pengamatan data energi surya</td><td>Datetime / object</td></tr><tr><td>SolarIrradiance</td><td>Intensitas radiasi matahari yang diterima permukaan panel surya.</td><td>Float</td></tr><tr><td>SunHeight</td><td>Ketinggian posisi matahari terhadap horizon pada waktu tertentu</td><td>Float</td></tr><tr><td>Temperature</td><td>Suhu udara pada lokasi pengamatan</td><td>Float</td></tr><tr><td>WindSpeed</td><td>Suhu udara pada lokasi pengamatan</td><td>Float</td></tr><tr><td>Int</td><td>intensitas kondisi cuaca tertentu yang diperoleh dari hasil API PVGIS.</td><td>Float</td></tr><tr><td>PowerOutput</td><td>Estimasi daya listrik yang dihasilkan panel surya. Atribut digunakan sebagai target prediksi.</td><td>Float</td></tr><tr><td>City</td><td>Nama kota lokasi pengambilan data panel surya di Indonesia</td><td>Object/String</td></tr></tbody></table>	Nama Atribut	Deskripsi	Tipe Data	Datetime	Tanggal dan waktu pengamatan data energi surya	Datetime / object	SolarIrradiance	Intensitas radiasi matahari yang diterima permukaan panel surya.	Float	SunHeight	Ketinggian posisi matahari terhadap horizon pada waktu tertentu	Float	Temperature	Suhu udara pada lokasi pengamatan	Float	WindSpeed	Suhu udara pada lokasi pengamatan	Float	Int	intensitas kondisi cuaca tertentu yang diperoleh dari hasil API PVGIS.	Float	PowerOutput	Estimasi daya listrik yang dihasilkan panel surya. Atribut digunakan sebagai target prediksi.	Float	City	Nama kota lokasi pengambilan data panel surya di Indonesia	Object/String
Nama Atribut	Deskripsi	Tipe Data																										
Datetime	Tanggal dan waktu pengamatan data energi surya	Datetime / object																										
SolarIrradiance	Intensitas radiasi matahari yang diterima permukaan panel surya.	Float																										
SunHeight	Ketinggian posisi matahari terhadap horizon pada waktu tertentu	Float																										
Temperature	Suhu udara pada lokasi pengamatan	Float																										
WindSpeed	Suhu udara pada lokasi pengamatan	Float																										
Int	intensitas kondisi cuaca tertentu yang diperoleh dari hasil API PVGIS.	Float																										
PowerOutput	Estimasi daya listrik yang dihasilkan panel surya. Atribut digunakan sebagai target prediksi.	Float																										
City	Nama kota lokasi pengambilan data panel surya di Indonesia	Object/String																										
Aspek khusus dari dataset	<i>Apakah datanya sparse? Sparsity berapa persen?</i> <i>Apakah datanya imbalanced? Berapa ratio-nya?</i> <i>Bagaimana outlier nya? Sebarannya seperti apa?</i> <i>Dan lain-lain</i> Berdasarkan hasil perhitungan sparsity, dataset memiliki sekitar 30,79% nilai nol. Nilai nol terutama muncul pada variabel PowerOutput dan SolarIrradiance saat malam hari ketika panel surya tidak menerima radiasi matahari. Oleh karena itu, sparsity pada dataset ini merupakan kondisi alami dan bukan disebabkan oleh missing value ataupun kesalahan pencatatan data. <i>Gambar 1. Distribusi PowerOutput</i> Histogram pada gambar 1, menunjukkan bahwa distribusi variabel PowerOutput cenderung right-skewed, dengan sebagian besar nilai berada pada rentang rendah atau nol. Kondisi ini terjadi karena pada malam hari panel surya tidak menghasilkan energi																											

	listrik akibat tidak adanya radiasi matahari. Nilai output tinggi hanya muncul pada waktu tertentu saat intensitas cahaya matahari meningkat.  <i>Gambar 2. Boxplot outlier variabel PowerOutput</i> Berdasarkan visualisasi boxplot, variabel PowerOutput memiliki beberapa nilai ekstrem pada sisi kanan distribusi data. Hal ini menunjukkan adanya output daya listrik yang jauh lebih tinggi dibandingkan mayoritas data lainnya. Kondisi tersebut kemungkinan dipengaruhi oleh tingginya intensitas radiasi matahari pada siang hari sehingga distribusi data bersifat right-skewed. Karena masih merepresentasikan kondisi aktual produksi energi surya, outlier tidak langsung dihapus dari dataset.
--	---

Rencana Metode

Teknik yang digunakan	Project ini menggunakan pendekatan Supervised Learning dengan metode regresi untuk memprediksi output energi panel surya berdasarkan data cuaca dan radiasi matahari. Teknik machine learning yang akan digunakan yaitu beberapa algoritma regresi, meliputi Random Forest Regression dan XGBoost Regression. Random Forest Regression dipilih karena mampu memodelkan hubungan yang kompleks dan nonlinear serta dapat bekerja dengan baik pada dataset berukuran besar. Sementara itu, XGBoost Regression digunakan karena memiliki kemampuan prediksi yang tinggi melalui mekanisme boosting yang dapat meningkatkan performa model secara bertahap. Kedua metode tersebut akan dibandingkan menggunakan matrik evaluasi untuk menentukan model terbaik dalam memprediksi output energi panel surya.
Alasan pemilihan teknik/algoritma	Pemilihan algoritma pada penelitian ini dilihat dari karakteristik dataset yang digunakan, yaitu data numerik time series dengan jumlah data yang besar serta hubungan antar variabel yang cenderung nonlinear. Variabel seperti radiasi matahari, suhu, posisi matahari, dan kecepatan angin memiliki pengaruh yang kompleks terhadap output energi panel surya sehingga diperlukan algoritma yang mampu menangkap pola hubungan tersebut dengan baik. Algoritma yang cocok untuk penelitian ini adalah Random Forest Regression karena mampu menangani data nonlinear, tahan terhadap noise, serta memiliki performa yang stabil pada dataset berukuran besar. Selain itu, algoritma ini dapat mengurangi risiko overfitting melalui teknik ensemble berbasis decision tree. Sedangkan, XGBoost Regression karena dikenal memiliki akurasi prediksi yang tinggi dan mampu meningkatkan performa model melalui teknik boosting secara bertahap. Algoritma ini juga efektif dalam menangani data kompleks dan sering digunakan pada permasalahan prediksi berbasis numerik. Kedua algoritma tersebut dipilih agar penelitian dapat membandingkan performa beberapa metode machine learning dalam menghasilkan prediksi output energi panel surya yang paling akurat.

Langkah-langkah umum pengerjaan	Proses pelatihan model dimulai dengan tahap preprocessing data, seperti menghapus data duplikat, melakukan transformasi tipe data, serta menyiapkan variabel input dan target. Selanjutnya dilakukan feature engineering pada variabel waktu untuk menghasilkan fitur tambahan seperti jam dan bulan agar model dapat memahami pola perubahan output energi panel surya berdasarkan waktu. Setelah preprocessing selesai, dataset dibagi menjadi data training dan data testing. Data training digunakan untuk melatih model machine learning, sedangkan data testing digunakan untuk mengevaluasi hasil prediksi model. Pada penelitian ini, proses pelatihan dilakukan menggunakan algoritma Random Forest Regression dan XGBoost Regression untuk memprediksi output energi panel surya berdasarkan data cuaca dan radiasi matahari. Kedua metode tersebut akan dibandingkan menggunakan matrik evaluasi untuk menentukan model terbaik dalam memprediksi output energi panel surya.
---------------------------------	---