

Proposal Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Rafael Hartono (24031554166)
Anggota 1	Athiyyatus Salisah (24031554223)
Anggota 2	Nurul Aini (24031554060)
URL Github	https://github.com/rafaelhartono8/166_060_223_Machine-Learning

Informasi Umum Proyek


Judul	<i>Analisis Perbandingan Algoritma Random Forest Regression, XGBoost, dan LSTM untuk Prediksi Daya Panel Surya Berdasarkan Data Meteorologi pada Wilayah 3T di Indonesia</i>
Topik	<i>Energi</i>
Pilihan Rumusan Masalah	3.8 Minimnya Pemanfaatan IoT dan AI untuk Ekspansi Elektrifikasi di Daerah 3T
Revisi?	Ya / Tidak

Deskripsi Rumusan masalah	<i>Tuliskan rationale atau significance atau background dari permasalahan yang diangkat.</i> <i>Apa yang mendesak dari permasalahan tersebut? Mengapa permasalahan tersebut belum terselesaikan? Apa tantangan penyelesaian masalah tersebut?</i> Deskripsi Indonesia memiliki target dalam mencapai <i>Net Zero Emission</i> melalui transisi energi terbarukan, di mana energi surya menjadi instrumen penting karena lokasinya yang berada di garis khatulistiwa. Namun, transisi pembangkit energi surya memiliki tantangan fluktuasi daya akibat cuaca yang dapat mengganggu stabilitas jaringan listrik. Permasalahan ini menjadi sangat krusial bagi daerah 3T (Tertinggal, Terdepan, Terluar) yang mengandalkan sistem listrik gabungan antara PLN dan energi surya (<i>microgrid</i>) atau mandiri tanpa cadangan PLN (<i>off-grid</i>). Di wilayah ini, ketidakpastian output daya bukan sekadar masalah efisiensi, melainkan risiko teknis yang dapat menyebabkan pemborosan siklus baterai hingga pemadaman listrik secara total. Saat ini, pemanfaatan AI untuk memprediksi daya masih sangat minim di daerah 3T. Sebagian besar operasional masih bersifat reaktif terhadap perubahan cuaca. Dibutuhkan sistem manajemen energi cerdas yang dapat memprediksi berapa daya yang akan dihasilkan beberapa jam ke depan untuk mengatur strategi pengisian baterai atau mengatur penggunaan beban secara otomatis. Tanpa prediksi yang akurat, ketersediaan energi yang stabil di daerah terpencil akan sulit tercapai. Hingga kini, tantangan utama adalah karakteristik iklim tropis Indonesia yang memiliki dinamika awan sangat cepat dan kelembapan tinggi, yang sangat berbeda dengan dataset wilayah subtropis. Selain itu, mengolah <i>big data</i> dari berbagai kota di Indonesia membutuhkan algoritma yang tidak hanya presisi secara akurasi, tetapi juga
---------------------------	---

	efisien secara komputasi agar dapat diimplementasikan pada perangkat IoT di masa depan. Rumusan Masalah 1. Bagaimana pengaruh variabel meteorologi tropis yang dinamis terhadap akurasi estimasi daya panel surya di berbagai wilayah Indonesia? 2. Sejauh mana efektivitas algoritma Random Forest Regression dibandingkan dengan XGBoost dalam menghasilkan prediksi yang presisi pada dataset skala besar? 3. Algoritma manakah yang memiliki performa akurasi dan efisiensi waktu komputasi terbaik?
Tujuan penelitian (Objectives)	<i>Tuliskan tahapan-tahapan, atau target penyelesaian</i> 1. Menganalisis korelasi antara variabel meteorologi khas iklim tropis Indonesia terhadap output daya listrik panel surya. 2. Membangun dan menguji model prediksi menggunakan algoritma Random Forest dan XGBoost. 3. Membandingkan performa kedua algoritma dengan evaluasi regresi untuk menemukan akurasi terbaik. 4. Mengevaluasi efisiensi komputasi <i>training time</i> dan penggunaan sumber daya dari masing-masing model untuk menentukan algoritma yang paling layak diimplementasikan pada sistem manajemen energi cerdas berbasis IoT di daerah 3T.
Referensi penelitian	<i>Tuliskan 3-5 penelitian terdahulu yang menjadi inspirasi pengerjaan proyek Anda. Penelitian terdahulu wajib: jurnal internasional dengan penerbit selain MDPI. Jurnal terbit setidaknya di tahun 2020. Tuliskan <u>link-link DOI-nya</u> saja cukup.</i> <i>Efficient Machine Learning Models for Solar Radiation Prediction Using Ensemble Techniques: A Case Study in Low-Rainfall Arid Climates</i> [1] 10.1109/ACCESS.2025.3579755 <i>Assessing Machine Learning Approaches for Photovoltaic Energy Prediction in Sustainable Energy Systems</i> [2] 10.1109/ACCESS.2024.3437191 <i>Cascade Predictive Model for Photovoltaic Solar Energy Generation Based on Machine Learning With Integration of Meteorological and Operational Variables: A Case Study in Lima, Peru</i> [3] 10.1109/ACCESS.2026.3670286 <i>Solar Energy Forecasting Using Machine Learning Techniques for Enhanced Grid Stability</i> [4] 10.1109/ACCESS.2025.3574093 <i>Recent Advances and Future Challenges of Solar Power Generation Forecasting</i> [5] 10.1109/ACCESS.2024.3496120


Informasi Detil Dataset

Sumber dataset	Dataset yang digunakan pada penelitian ini diperoleh melalui proses scraping data dari layanan API resmi PVGIS (Photovoltaic Geographical Information System) milik European Commission Joint Research Centre (JRC). API yang digunakan adalah layanan non-interactive service PVGIS 5.2 yang dapat diakses melalui link ini . Proses pengambilan data dilakukan secara otomatis menggunakan bahasa pemrograman Python dengan bantuan library requests dan pandas. Data diambil melalui API PVGIS untuk beberapa kota di Indonesia dengan parameter koordinat lintang dan bujur (latitude dan longitude) masing-masing kota. Data yang diambil mencakup periode tahun 2015 hingga 2020 dengan resolusi data per jam (hourly data). Data hasil scraping yaitu sebanyak 2439968 baris, 8 kolom, dan ukuran file sebesar 122.12 MB.		
Deskripsi awal fitur dataset	Tuliskan nama-nama atribut dataset berikut dengan: deskripsi dan tipe data nya.		
	Dataset yang digunakan dalam proyek ini terdiri dari beberapa atribut yang berkaitan dengan kondisi lingkungan dan estimasi energi panel surya. Berikut merupakan deskripsi masing-masing atribut beserta tipe datanya:		
	Nama Atribut	Deskripsi	Tipe Data
	Datetime	Tanggal dan waktu pengamatan data energi surya	Datetime object /
	SolarIrradiance	Intensitas radiasi matahari yang diterima permukaan panel surya.	Float
	SunHeight	Ketinggian posisi matahari terhadap horizon pada waktu tertentu	Float
	Temperature	Suhu udara pada lokasi pengamatan	Float
	WindSpeed	Suhu udara pada lokasi pengamatan	Float
	Int	intensitas kondisi cuaca tertentu yang diperoleh dari hasil API PVGIS.	Float
	PowerOutput	Estimasi daya listrik yang dihasilkan panel surya. Atribut digunakan sebagai target prediksi.	Float
City	Nama kota lokasi pengambilan data panel surya di Indonesia	Object/String	
Aspek khusus dari dataset	Apakah datanya sparse? Sparsity berapa persen? Apakah datanya imbalanced? Berapa ratio-nya? Bagaimana outlier nya? Sebarannya seperti apa? Dan lain-lain Berdasarkan hasil perhitungan sparsity, dataset memiliki sekitar 30,79% nilai nol. Nilai nol terutama muncul pada variabel PowerOutput dan SolarIrradiance saat malam hari ketika panel surya tidak menerima radiasi matahari. Oleh karena itu, sparsity pada dataset ini merupakan kondisi alami dan bukan disebabkan oleh missing value ataupun kesalahan pencatatan data.		



Gambar 1. Distribusi PowerOutput

Histogram pada gambar 1, menunjukkan bahwa distribusi variabel PowerOutput cenderung right-skewed, dengan sebagian besar nilai berada pada rentang rendah atau nol. Kondisi ini terjadi karena pada malam hari panel surya tidak menghasilkan energi listrik akibat tidak adanya radiasi matahari. Nilai output tinggi hanya muncul pada waktu tertentu saat intensitas cahaya matahari meningkat.



Gambar 2. Boxplot outlier variabel PowerOutput

Berdasarkan visualisasi boxplot, variabel PowerOutput memiliki beberapa nilai ekstrem pada sisi kanan distribusi data. Hal ini menunjukkan adanya output daya listrik yang jauh lebih tinggi dibandingkan mayoritas data lainnya. Kondisi tersebut kemungkinan dipengaruhi oleh tingginya intensitas radiasi matahari pada siang hari sehingga distribusi data bersifat right-skewed. Karena masih merepresentasikan kondisi aktual produksi energi surya, outlier tidak langsung dihapus dari dataset.

Rencana Metode

Teknik yang digunakan	Project ini menggunakan pendekatan Supervised Learning dengan metode regresi untuk memprediksi daya panel surya berdasarkan data meteorologi pada wilayah 3T Indonesia. Teknik yang digunakan meliputi preprocessing data, feature engineering time series, serta pemodelan menggunakan Random Forest Regression, XGBoost Regression, dan Long Short-Term Memory (LSTM). Ketiga metode tersebut akan dibandingkan menggunakan matrik evaluasi untuk menentukan model terbaik dalam memprediksi output energi panel surya.
Alasan pemilihan teknik/algoritma	Pemilihan algoritma pada penelitian ini dilihat dari karakteristik dataset yang digunakan, yaitu data numerik time series dengan jumlah data yang besar serta hubungan antar variabel yang cenderung nonlinear. Variabel seperti radiasi matahari, suhu, posisi matahari, dan kecepatan angin memiliki pengaruh yang kompleks terhadap output energi panel surya sehingga diperlukan algoritma yang mampu menangkap pola hubungan tersebut dengan baik. Algoritma yang cocok untuk penelitian ini adalah Random Forest Regression karena mampu menangani data

	nonlinear, tahan terhadap noise, serta memiliki performa yang stabil pada dataset berukuran besar. Selain itu, algoritma ini dapat mengurangi risiko overfitting melalui teknik ensemble berbasis decision tree. XGBoost Regression dipilih karena dikenal memiliki akurasi prediksi yang tinggi dan mampu meningkatkan performa model melalui teknik boosting secara bertahap. Algoritma ini juga efektif dalam menangani data kompleks dan sering digunakan pada permasalahan prediksi berbasis numerik. Sedangkan, Long Short-Term Memory (LSTM) dipilih karena mampu mempelajari pola temporal dan dependensi jangka panjang pada data time series. LSTM sangat sesuai digunakan untuk forecasting daya panel surya karena data energi dan meteorologi memiliki pola berurutan yang dipengaruhi oleh kondisi waktu sebelumnya. Ketiga algoritma tersebut dipilih agar penelitian dapat membandingkan performa beberapa metode machine learning dalam menghasilkan prediksi output energi panel surya yang paling akurat.
Langkah-langkah umum pengerjaan	Langkah Langkah pengerjaan meliputi: 1. Pengumpulan data dengan cara Scraping dari layanan API resmi PVGIS (Photovoltaic Geographical Information System)I pada beberapa wilayah 3T Indonesia. 2. Melakukan preprocessing data berupa pembersihan data duplikat, transformasi tipe data, penanganan nilai kosong, dan normalisasi data. 3. Melakukan feature engineering time series dengan membuat fitur temporal seperti lag feature, rolling mean, dan fitur waktu untuk menangkap pola historis data. 4. Membagi data menjadi data pelatihan dan data pengujian 5. Melakukan pelatihan model menggunakan Random Forest, XGBoost, dan Long Short-Term Memory. 6. Melakukan prediksi daya panel surya menggunakan masing-masing model. 7. Mengevaluasi performa model menggunakan matrik Evaluasi. 8. Membandingkan hasil prediksi dan menentukan model terbaik untuk prediksi daya panel surya pada wilayah 3T Indonesia.